UBER PICKUPS

Où placer les chauffeurs avant le pic de demande ?

Clustering non supervisé / K-Means / DBSCAN

4,5 M	6 mois	54 485	8
pickups	avril à septembre 2014	vendredi 18h	hot-zones



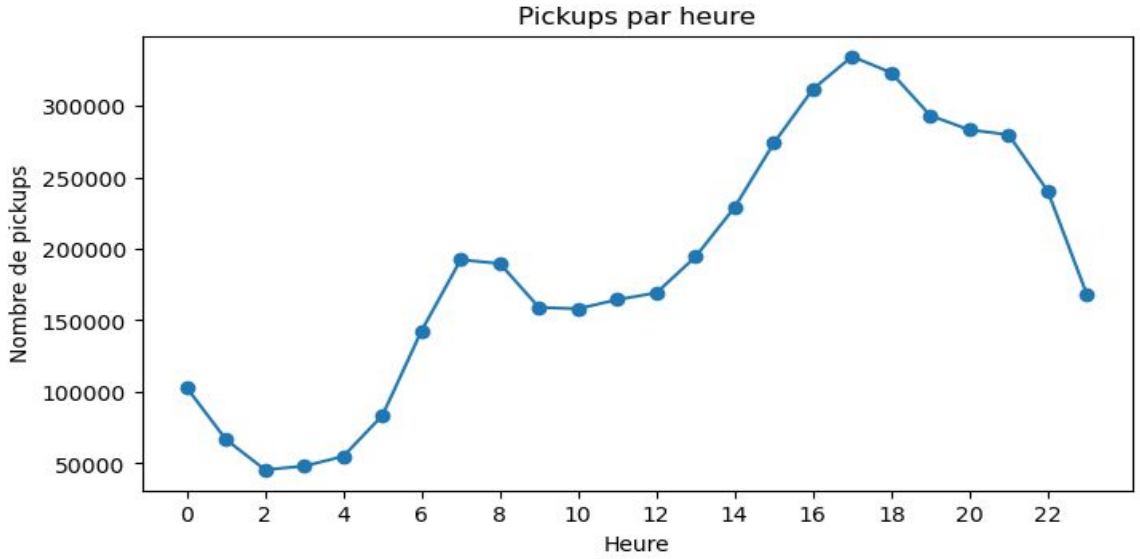
Problématique

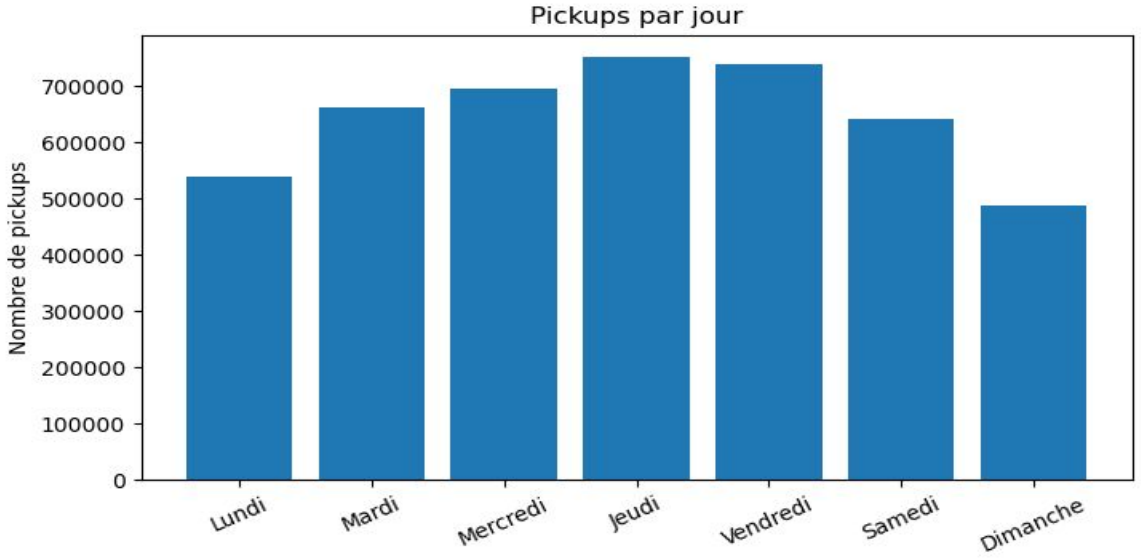
Transformer des positions historiques en recommandations simples pour réduire les temps morts des chauffeurs et rapprocher l'offre de la demande.

Schuyler Gilmer Gonçalves · Bloc 3 CDSD · RNCP 35288

1. Avant de chercher où, il faut savoir quand

Avant de chercher où, il faut chercher quand





Une double bosse

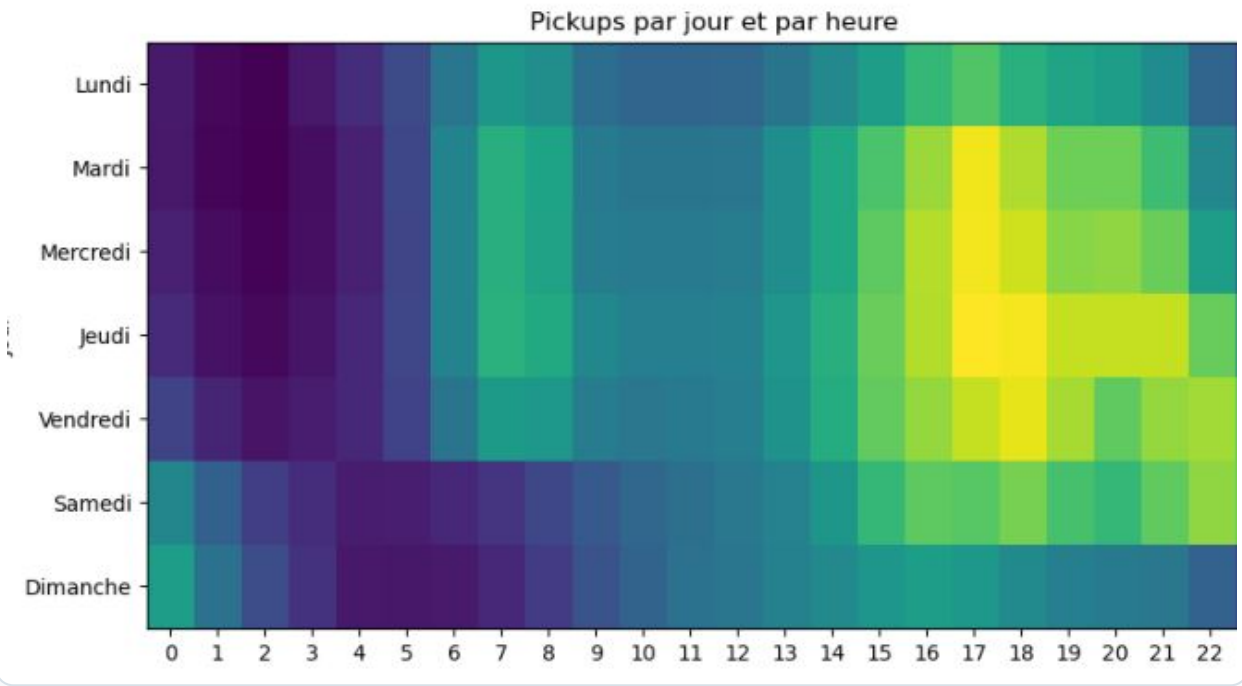
Un pic le matin, un pic de fin de journée nettement plus fort, et un creux très net la nuit.

Jeudi et vendredi en tête

751 430 courses le jeudi contre 486 701 le dimanche

3. Heatmap Jour x Heures

La demande varie fortement selon le jour et l'heure : une carte unique serait trop moyenne.

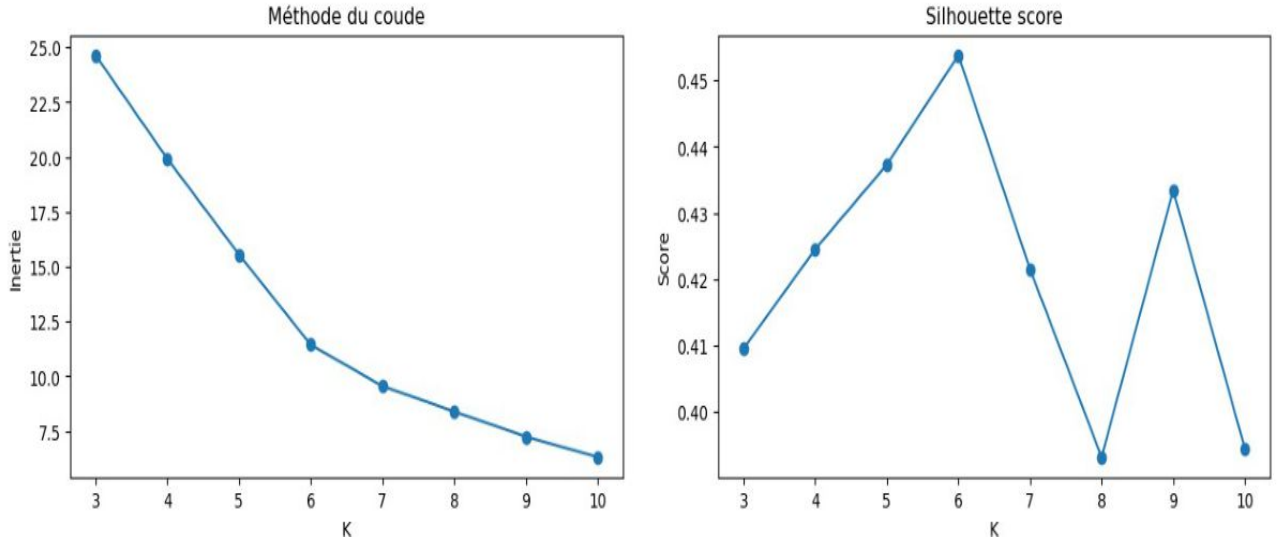


Insights clés

- En semaine, le pic arrive surtout vers 17h.
- Le vendredi culmine à 18h : bon cas d'étude pour la suite.
- Le samedi culmine à 22h : profil sorties, pas domicile-travail.
- Conclusion : les hot-zones doivent être recalculées par jour et par heure.

3. Choisir le découpage : statistique + métier

K-Means impose le nombre de zones ; le choix de K doit rester lisible pour un chauffeur.



Décision : K = 8 Le coude indique une zone raisonnable entre 6 et 8. Le silhouette ne tranche pas seul : il varie peu et reste non monotone.

Deux algorithmes, deux usages

K-Means

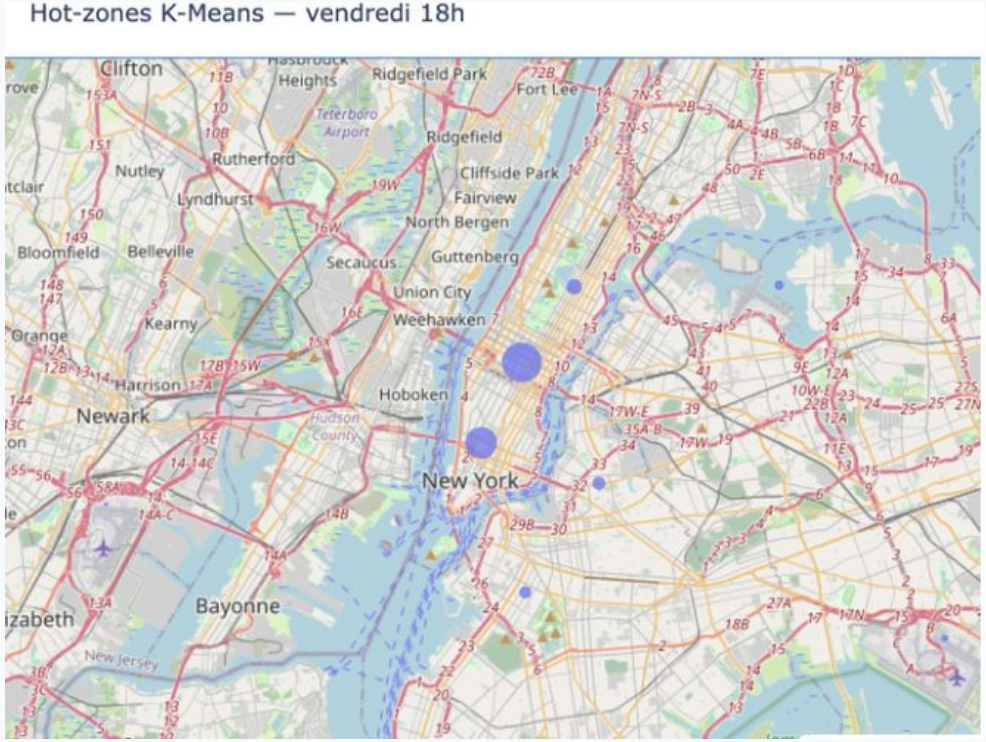
- Nombre de zones fixé à l'avance.
- Chaque centre devient une consigne chauffeur.

DBSCAN

- Détecte les zones par densité.
- Repère le bruit et les points atypiques.

4. Résultat K-Means : 8 hot-zones actionnables

Le modèle résume 54 485 pickups du vendredi 18h en quelques points de repositionnement.



Zone	Pickups	Part
1 · Midtown	25 469	**46,7 %**
2 · Manhattan sud	16 445	**30,2 %**
3 · Upper East Side	4 115	7,6 %
4 · Williamsburg	2 918	5,4 %
5 · Brooklyn (Park Slope)	2 715	5,0 %
6 · LaGuardia	1 542	2,8 %
7 · JFK	910	1,7 %
8 · Newark	371	0,7 %

Lecture business

46,7 %
zone 1

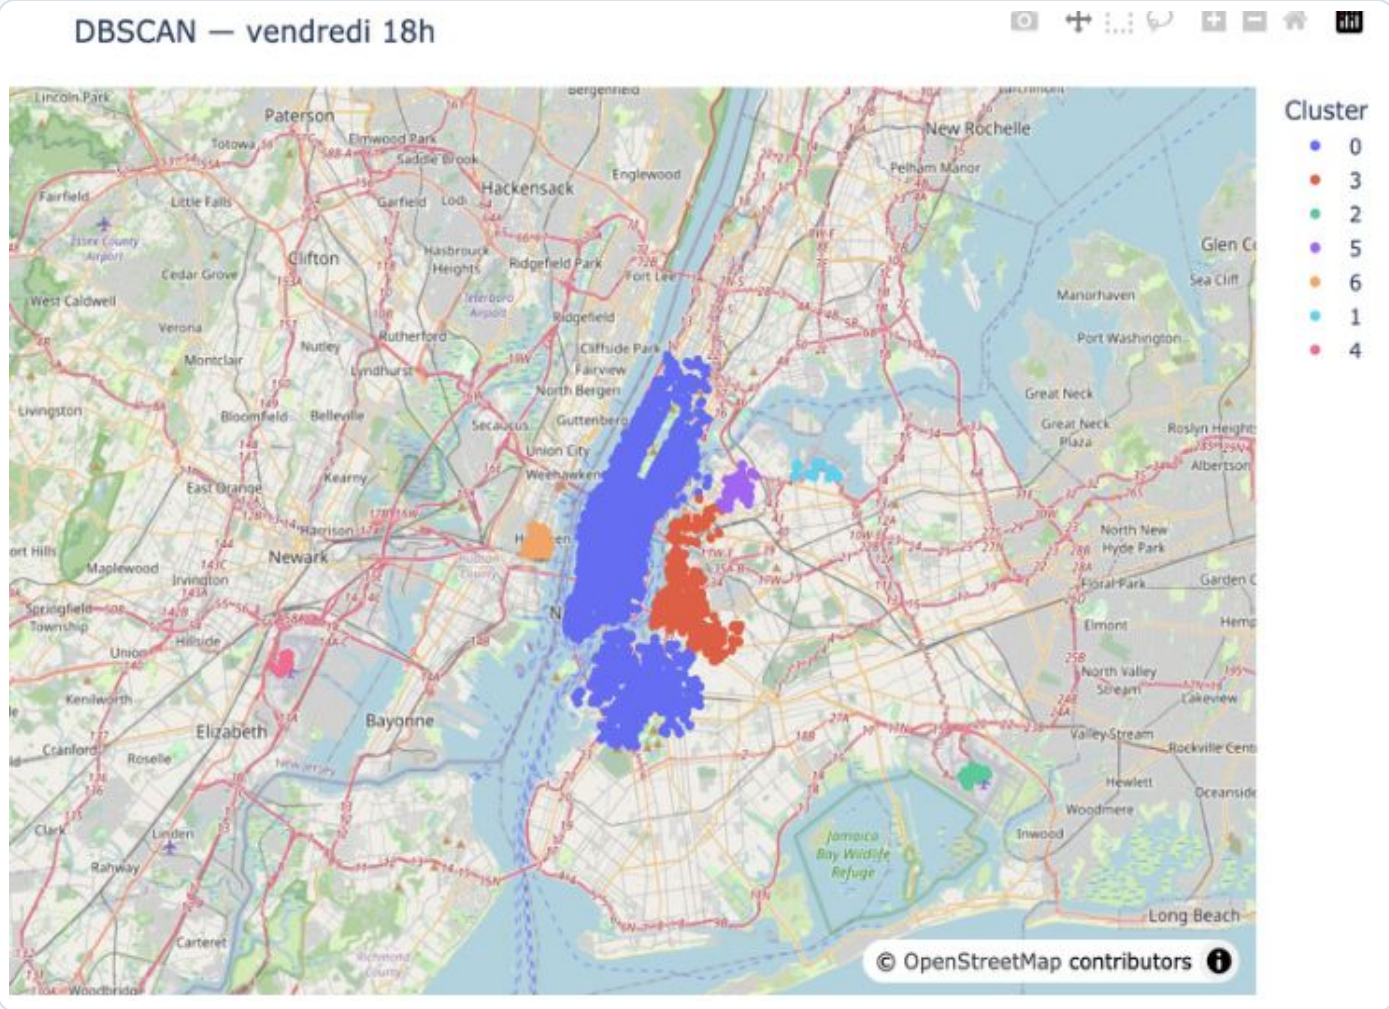
30,2 %
zone 2

≈77 %
top 2

- Deux zones concentrent l'essentiel de la demande.
- La taille des cercles représente le volume de pickups associé.
- Les centres deviennent des points simples à afficher dans l'application chauffeur.

5. DBSCAN : valider la densité autrement

Même créneau, même échantillon : DBSCAN confirme les pôles et détecte le bruit.



Ce que DBSCAN apporte

7	4,8 %	≈0,7k m
clusters	bruit	eps

- Il n'impose pas le nombre de zones.
- Il regroupe par densité et isole les points atypiques.
- Il confirme les grands pôles observés avec K-Means.

6. K-Means ou DBSCAN ? Le choix dépend de l’usage

Les métriques seules ne suffisent pas : il faut choisir la méthode adaptée au besoin opérationnel.

Critère	K-Means	DBSCAN
Nombre de clusters	8 fixes	7 détectés
Bruit	0 %	4,8 %
Silhouette	0,430	0,156*
Points forts	stable · simple · opérationnel	densité · formes libres · bruit
Usage retenu	recommandation chauffeur	analyse complémentaire

Pourquoi ne pas surinterpréter le silhouette ?

Le silhouette récompense des clusters compacts et sphériques : il avantage mécaniquement K-Means.
DBSCAN cherche surtout des zones denses, avec des formes potentiellement irrégulières.

Décision finale

K-Means pour l’usage

- Nombre fixe de centres.
- Aucun pickup non affecté.
- Sortie simple à afficher aux chauffeurs.

DBSCAN en complément

- Validation des zones denses.
- Détection du bruit et des poches isolées.

7. Recommandation

Passer d’une carte statique à une recommandation dynamique par jour et par heure.

1 **Historique pickups** → 2 **Filtrer jour + heure** → 3 **Calculer K-Means** → 4 **Afficher hot-zones**

Ce que je recommande

- Recalculer les zones par créneau.
- Repositionner avant le pic, pas après.
- Prioriser les 2 zones qui concentrent 77 % de la demande.

Limites

- Données de 2014.
- Pickups réalisés vs demandes annulées.
- Trafic, météo et événements non intégrés.

Le projet démontre la capacité à transformer des données non labellisées en décision métier : des hot-zones simples, évaluées et actionnables.